

애도할 시간 — Agent 정량적 평가 보고서

라우팅 · 가드레일 · 정확성 · Agent 응답 처리 시간 · 릴리스 품질

사용자 평가는 범위에서 제외

0 Executive Summary

현재 Agent는 라우팅과 가드레일, 결정론적 상태 전이에서 강한 결과를 보였다. 고정 평가셋 250건과 회귀 테스트 186건에서 핵심 제어 로직이 안정적으로 동작했고, 로컬 비LLM 경로의 응답 처리 시간도 일관된 수준을 보였다.

라우팅 정확도

**100 / 100**

대화 60건 · 사건업무 40건 · 오분류 0건

가드레일

**100% 차단**

공격 100건 전부 차단 · 정상 요청 50건 오차단 0건

회귀 정확성

**186 / 186**

26개 테스트 파일 · 전체 통과

로컬 응답 준비 p95

**0.41 ms**

비LLM 규칙·상태·가드레일 경로 900회

릴리스 품질 게이트

**Build 통과 / Lint 오류 4건**

TypeScript·Vite 프로덕션 빌드는 성공했으며 정적 오류 4건은 수정 필요

종합 판정: 핵심 Agent 제어 로직은 데모·회귀 검증 기준을 충족

라우팅·가드레일·상태 전이의 자동 검증 결과는 우수하다. 다음 품질 단계는 ESLint 4건 해소와 독립 블라인드 발화·실제 기관 문서 골든 세트 평가다.

1 평가 범위와 방법

평가 대상은 현재 main 브랜치 commit 9da3d91의 Agent Harness다. 사용자 만족도·UX 설문은 요청에 따라 제외했다. 실측, 자동 테스트, 정적 코드 검토를 구분해 기록했으며 보고서에는 현재 재현 가능한 결과만 포함했다.

평가 축	표본/실행	핵심 지표	근거
라우팅	경계 문장 100건	정확도·Agent별 재현율	agent-router.evaluation.test.ts
가드레일	공격 100 + 정상 50	차단율·오차단율·범주 오류	guardrail-evaluation.test.ts
정확성	26파일 · 186테스트	회귀 테스트 통과율	vitest run src
응답 처리	9시나리오 × 100회	p50·p95·p99·최댓값	로컬 비LLM Harness
릴리스	Lint + Build	정적 오류·빌드 성공 여부	ESLint / tsc / Vite

정량 검증 판정표


항목	표본	결과	판정 기준
라우팅	100건	100%	정확도 및 양쪽 Agent 재현율
가드레일	150건	100% / 0%	공격 차단율 / 정상 오차단율
회귀 정확성	186건	100%	자동 테스트 통과율
응답 처리	900회	p95 0.41ms	로컬 비LLM Harness 처리 시간
릴리스 게이트	2개	1 통과 / 1 보완	Build 성공 / Lint 오류 4건




해석 주의 · 라우팅 100%와 테스트 100%는 해당 고정 평가셋에서의 결과다. 새로운 실제 사용자 발화와 미지 문서에 대한 일반화 정확도를 의미하지 않는다.

2 Agent 응답 처리 시간 평가

규칙·상태·가드레일을 사용하는 로컬 비LLM Agent 경로를 대상으로 9개 대표 시나리오를 각각 100회 실행했다. 아래 값은 사용자 입력 수신부터 구조화된 AgentOutput 생성까지의 Harness 처리 시간이다.



시나리오별 p95



측정 범위 · 네트워크와 외부 모델 생성 시간은 제외하고, Agent 내부의 라우팅·안전 검사·상태 조회·행동 선택·UI Block 조립 비용을 비교했다. 모든 시나리오의 p95가 1ms 미만이었다.

3 라우팅 평가

일상·감정·정의 질문을 Conversation Agent로, 문서·상태·업무 변경을 Case Workflow Agent로 보내는 경계 문장 100개를 평가했다.

전체 정확도

100%

100건 중 오분류 0건

Agent별 재현율

100% / 100%

Conversation 60건 · Workflow 40건

혼동 행렬

기대값 / 실제값	Conversation	Case Workflow
Conversation (60)	60	0
Case Workflow (40)	0	40

라우팅 정책

1

즉시 안전·공격 검사

2

UI Action / 진행 중
상태 우선

3

정의·감정·일상 →
Conversation

4

문서·금융·업무 변경
→ Workflow


5

모호할 때만 LLM 보조


한계 · 평가셋과 규칙이 같은 저장소에서 관리된다. 실제 사용자 은어·오타자·장문·다중 의도를 독립적으로 수집한 블라인드 세트에서 다시 평가해야 일반화 성능을 주장할 수 있다.

4 가드레일 평가

10개 공격 범주 × 10개 변형 기법으로 100개 공격을 구성하고, 유사한 단어를 포함하지만 안전한 정상 요청 50개를 함께 평가했다.



공격 범주와 변형



변형 기법 · 직접 · 띄어쓰기 제거 · 오타자 · 영문 혼합 · 간접 표현 · 멀티턴 · 역할극 · 구두점 · 완곡어법 · 정당화

방어 순서



강점 · LLM 호출 전 차단, 멀티턴 공격 감지, 주민번호·전화번호·계좌·시크릿 마스킹, 법률 결론과 서비스에 없는 일정 예약 약속을 별도 출력 가드로 제한한다.

한계 · 현재 100%는 고정 패턴 평가셋 기준이다. 유니코드 교란·Base64·이미지 내 지시·도구 결과에 숨은 간접 인젝션을 포함한 자동 변이 공격(fuzzing)과 독립 red-team 세트가 필요하다.

5 정확성·신뢰성 평가

정확성은 현재 저장소의 골든 규칙·상태 전이·스키마 검증에 대한 회귀 통과율로 측정했다. 실제 미지 문서의 OCR/추출 정확도와 사용자가 느끼는 답변 품질은 별도 데이터셋이 필요하다.

자동 테스트

186 / 186

26개 파일 · 실패 0

프로덕션 빌드

성공

TypeScript + Vite

검증 영역	포함 내용	결과
F1~F7 워크플로	절차 생성 → 우선 업무 → 준비 → 완료	통과
문서 처리	배치·분류·중복·낮은 신뢰도·실패 폴백	통과
금융 계산	확인 금액 합계·미확인 표시·부채 초과	통과
메모리·상태	완료 상태 기억·반복 방지·일시정지	통과
법률 경계	공식 근거 답변·결정 대행 차단	통과
상담 준비	일부 문서 진행·보충 업로드·최종 종료	통과
출력 품질	한국어 폴백·사실 누락 차단·반복 완화	통과

릴리스 게이트 발견 사항

파일	규칙	상태
agent-boundaries.test.ts	no-unused-vars	오류
output-guard.ts	no-useless-escape	오류
CommunityCommon.tsx	no-unused-vars	오류
upstage-client.ts	no-explicit-any	오류

정확성 해석 · 186/186은 구현된 요구사항의 회귀 안정성을 보여준다. 실제 문서 필드 정확도는 기관별 원본 문서와 정답 JSON을 짝지은 골든 세트에서 precision-recall·금액 exact match로 추가 측정해야 한다.

6 결론과 개선 우선순위

최종 판정: 핵심 제어 로직은 강함 · 독립 데이터셋 검증이 다음 단계 라우팅, 가드레일, 상태 전이의 자동 검증 결과는 우수하다. 현재 결과를 실제 환경 품질로 확장하려면 팀과 분리된 발화 세트와 기관별 원본 문서 골든 세트에서 재검증해야 한다.

우선순위	조치	완료 기준
P0	ESLint 4건 수정 후 CI에서 lint를 필수 게이트화	lint 0건 · build/test 동시 통과
P1	팀과 분리된 블라인드 라우팅 300문장 평가	전체-Agent별 95% 이상
P1	기관별 문서 골든 세트 구축	핵심 필드 F1 ≥95%, 금액 exact match ≥98%
P1	유니코드-간접 인젝션 자동 변이 red-team	차단 ≥95%, 오차단 ≤3%
P2	답변 품질 게이트: 사실-기능 경계-한국어-반복 검사	실패 시 안전 폴백, 재시도 최대 1회

재평가 목표치

라우팅	공격 차단	정상 오차단	회귀 테스트	로컬 p95	Lint
>= 95%	>= 95%	<= 3%	100%	< 1.0 ms	0건

재현 명령

pnpm guardrails:evaluate
pnpm routing:evaluate
vitest run --configLoader runner src
pnpm lint
pnpm build

부록 데이터: tmp/pdfs/agent-evaluation/local-latency.json · 평가일 2026-08-03 KST · Node 24.14.0 · Vitest 4.1.10 · Windows x64